Reporte: Q-learning en Cliff Walking

El camino de 13 pasos pegado al acantilado es óptimo porque el entorno aplica una penalización constante de -1 por cada paso sin factor de descuento, de modo que el recorrido más corto desde S = (3, 0) hasta G = (3, 11) -1 paso al Norte, 11 al este por la fila 2 y 1 al sur- minimiza la distancia total obteniendo un retorno de -13. Por otro lado, la curva de entrenamiento se mantiene por debajo de -13 debido a que la conducta ε-greedy (ε = 0.1) ejecuta un 10% de acciones aleatorias de exploración que, al transitar tan cerca del borde, ocasionan caídas accidentales con una severa penalización de -100, desplomando el promedio del episodio a pesar de que la política evalúa de forma determinista la ruta mas optima. Finalmente, cuando el agente se cae al acantilado, el estado siguiente en el backup de Q-learnging es s’ = S 0 (3, 0); este paso no se trata como un estado terminal porque caer no termina la secuencia episódica, sino que reubica al agente en el punto de inicio para que continua la trayectoria, manteniendo activo el valor futuro estimado en el calculo TD y dejando la meta G = (3, 11) como el único estado terminal que anula la expectativa a cero.